INFORME EJECUTIVO DE CIENCIA DE DATOS Y POLÍTICAS PÚBLICAS

Determinantes Sociodemográficos, Económicos y Geográficos de la Deserción Escolar en Bolivia

Análisis exploratorio multivariado, modelado supervisado e interpretabilidad (XAI) basado en la Encuesta de Hogares 2025 (INE)

Fuente de Datos: Encuesta de Hogares 2025 (Módulo Persona, N = 39,485) **Población Objetivo:** 6 a 19 años (n = 10,448)

> PREGUNTA CENTRAL DE INVESTIGACIÓN
>
> **¿Cuáles son los factores sociodemográficos, económicos y geográficos que más influyen en la deserción e inasistencia escolar en Bolivia?**

1. Resumen Ejecutivo y Metodología

El presente estudio aborda el fenómeno de la desvinculación e irregularidad escolar en Bolivia mediante un flujo de ingeniería de datos y aprendizaje automático aplicado sobre los microdatos de la Encuesta de Hogares 2025 del Instituto Nacional de Estadística (INE). Para garantizar la representatividad poblacional en la fase exploratoria, se incorporaron los factores de expansión oficiales (`factor`) procesados mediante consultas analíticas en DuckDB sobre la población en edad escolar normativa (6 a 19 años).

La variable objetivo se construyó a partir de la Condición de Matriculación y Asistencia (`cmasi`), evaluando tanto su comportamiento agregado ponderado (media muestral de 1.95) como su formulación binaria para la detección de riesgo de inasistencia o deserción. Posteriormente, se entrenaron y validaron modelos ensamble basados en árboles de decisión (Random Forest y XGBoost) bajo validación cruzada estratificada de 5 pliegues, culminando con el análisis de valores SHAP (*SHapley Additive exPlanations*) para traducir las predicciones en evidencia accionable.

2. Hallazgos Clave y Patrones Geográficos y Socioeconómicos

El análisis exploratorio espacial y multivariado (implementado mediante cartografía interactiva en Folium y desagregaciones en Plotly) permitió identificar tres patrones estructurales que explican la distribución del riesgo escolar en el territorio nacional:

- **Homogeneidad de género frente a brechas territoriales:** A nivel nacional, el indicador promedio ponderado de asistencia muestra paridad entre hombres (51% de la muestra escolar) y mujeres (49%). Sin embargo, la proyección geoespacial departamental evidencia disparidades en el volumen poblacional y en las tasas de rezago entre el eje troncal (La Paz, Cochabamba, Santa Cruz) y departamentos con mayor dispersión geográfica como Potosí, Beni y Pando.

- **Interacción entre pobreza por ingreso y área geográfica:** El análisis multivariado cruzando la línea de pobreza (`p0`) con el área de residencia (`area`) confirma que la vulnerabilidad económica ejerce un efecto asimétrico. En el área rural, los hogares en situación de pobreza concentran una proporción significativamente mayor de adolescentes que interrumpen su trayectoria educativa al transitar del nivel primario al secundario.
- **Segmentación de perfiles mediante Clustering (K-Means):** La agrupación no supervisada sobre edad, años de estudio acumulados, ingreso per cápita del hogar (`yhogpc`), nivel educativo del jefe de hogar y ratio de dependencia permitió distinguir tres estratos claros en la población escolar boliviana.

Clúster Identificado	Caracterización Socioeconómica	Dinámica Educativa Observada
Perfil 1: Vulnerabilidad Estructural	Ingresos per cápita deprimidos, alta dependencia demográfica y baja escolaridad del jefe de hogar.	Mayor concentración de rezago escolar (brecha entre edad cronológica y años de estudio aprobados).
Perfil 2: Clase Media Estándar	Núcleo mayoritario nacional con ingresos estables vinculados a comercio y servicios urbanos/periurbanos.	Trayectoria educativa regular acorde a la edad normativa, con sensibilidad ante choques económicos.
Perfil 3: Alta Estabilidad y Acceso	Hogares en deciles superiores de ingreso per cápita y jefes de hogar con educación superior o técnica.	Continuidad escolar sostenida hasta el bachillerato y alto acceso a conectividad digital (`s03c_16a`).

3. Desempeño del Modelado Supervisado

Para identificar con precisión qué variables determinan el riesgo de desvinculación escolar, se evaluaron dos arquitecturas supervisadas sobre 18 variables predictoras individuales, familiares y contextuales (n = 10,448 registros válidos en edad escolar).

Algoritmo Evaluado	Estrategia de Validación	ROC-AUC Promedio	Desviación Estándar
Random Forest Classifier	Stratified K-Fold (5 pliegues)	0.9518	± 0.0040
XGBoost Classifier	Stratified K-Fold (5 pliegues)	0.9536	± 0.0069

Ambos modelos demostraron una capacidad discriminante sobresaliente (AUC superior a 0.95) y alta estabilidad entre pliegues, seleccionándose **XGBoost** como modelo de referencia para el análisis de explicabilidad por su superioridad marginal en la curva ROC.

4. Interpretabilidad del Modelo (XAI) mediante Valores SHAP

A través de la descomposición de valores SHAP aplicada sobre el conjunto de prueba, se cuantificó la contribución marginal de cada predictor en la probabilidad estimada por el modelo XGBoost:

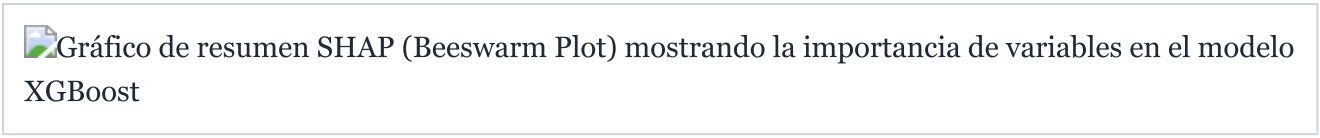

Gráfico de resumen SHAP (Beeswarm Plot) mostrando la importancia de variables en el modelo XGBoost

Figura 1. Importancia Global y Dirección de Impacto (Valores SHAP - Modelo XGBoost). Cada punto representa un individuo de la muestra de evaluación; el color fucsia indica valores altos de la característica y el azul valores bajos.

Los resultados empíricos del gráfico SHAP responden de manera directa a la pregunta de investigación al establecer la jerarquía exacta de los factores determinantes:

1. **Edad cronológica (`edad`) y Años de estudio aprobados (`aestudio`):** Constituyen los dos predictores con mayor peso global. El modelo detecta que el riesgo de desvinculación se dispara en la transición hacia la adolescencia tardía (15 a 19 años), especialmente cuando existe un desfase entre la edad del estudiante y los años de instrucción acumulados.
2. **Capital educativo del hogar (`niv_ed_jefe`):** El nivel educativo alcanzado por la jefa o jefe del hogar actúa como un factor protector determinante; hogares encabezados por adultos con mayor instrucción presentan menor probabilidad de inasistencia escolar en sus dependientes.
3. **Inserción laboral temprana (`trabajo_semana_pasada`):** Haber trabajado al menos una hora durante la semana de referencia (`s04a_01`) desplaza de forma consistente la predicción hacia el riesgo de desvinculación, evidenciando la competencia directa entre el trabajo juvenil y la permanencia en el sistema educativo.
4. **Alfabetización básica y contexto departamental (`sabe_leer_escribir`, `depto`):** La ausencia de competencias lectoescritoras básicas y la ubicación territorial en departamentos específicos modulan la probabilidad basal de abandono.

5. Recomendaciones de Políticas Públicas Basadas en Evidencia

Con base estricta en los hallazgos del análisis exploratorio y la importancia de variables demostrada por los valores SHAP, se proponen tres líneas de intervención focalizada:

> ### 1. Sistema de Alerta Temprana Basado en Rezago Edad-Grado (`edad` vs. `aestudio`)
>
> Dado que la interacción entre edad y años de estudio aprobados es el principal predictor del modelo, el Ministerio de Educación debe implementar un protocolo automatizado en el Registro Único de Estudiantes (RUDE) que identifique a todo alumno con un desfase igual o superior a un año respecto a su cohorte etaria. Estos estudiantes deben recibir tutorías de nivelación acelerada antes de cumplir los 15 años, punto crítico donde la probabilidad de abandono se incrementa abruptamente.

> ### 2. Incentivos Condicionados Focalizados en Adolescentes Trabajadores (`trabajo_semana_pasada`)
>
> Considerando el fuerte impacto positivo de la variable de ocupación laboral sobre la deserción escolar en el análisis SHAP, las transferencias monetarias existentes (como el Bono Juancito Pinto) deben complementarse con un esquema de becas de retención secundaria y modalidades educativas flexibles (horarios nocturnos o semipresenciales) dirigidas específicamente a jóvenes de 14 a 19 años en hogares pertenecientes al Perfil 1 de vulnerabilidad económica y área rural.

> ### 3. Intervención Familiar y Alfabetización de Adultos en Hogares Vulnerables (`niv_ed_jefe`)
>
> Debido a que el nivel educativo del jefe de hogar emerge como el tercer determinante estructural más relevante, las políticas de retención escolar no deben limitarse al estudiante. Se recomienda articular los programas de educación alternativa y post-alfabetización (como el Programa Nacional de Post-alfabetización) con las unidades educativas de municipios rurales y periurbanos con mayor incidencia de pobreza (`p0`), fortaleciendo el acompañamiento familiar en el hogar.